

UNIwersytet Śląski w Katowicach

Wydział Nauk Ścisłych i Technicznych

Informatyka Inżynierska

Bartosz Ziętek

Nr albumu: 350967

**System do analizy sentymentu wiadomości
finansowych w kontekście prognozowania ruchów
giełdowych**

PRACA DYPLOMOWA INŻYNIERSKA

Promotor: dr hab. inż. Rafał Doroz, prof. UŚ

Sosnowiec, 2026

Streszczenie

Niniejsza praca prezentuje projekt oraz implementację systemu przeznaczonego do autonomicznej analizy sentymentu wiadomości finansowych, którego zadaniem jest predykcja wzrostu lub spadku cen akcji w ciągu 24 godzin. System korzysta z gotowych narzędzi przetwarzania języka naturalnego NLP (Natural Language Processing) w połączeniu z algorytmami uczenia maszynowego.

Do analizy sentymentu wykorzystano model FinBERT, który jest wyspecjalizowaną wersją modelu BERT, skupiającą się na analizie tekstów finansowych. Z punktu widzenia technicznego, największym wyzwaniem przy tworzeniu projektu, była obróbka danych oraz test funkcjonalności systemu.

Wyniki działania systemu wskazują, że istnieje wartość w automatycznej analizie sentymentu wiadomości finansowych - model w przybliżeniu 63% przypadków poprawnie przewiduje, czy cena akcji spadnie, nie zmieni się, czy wzrośnie. Gdy porównamy ten wynik z losowym zgadywaniem (50%), to możemy dojść do wniosku, że jest sens w zgłębianiu tego tematu. Co ważniejsze, model bardzo skutecznie unika strat - stara się nie ryzykować w swoich predykcjach.

Oświadczenie autora pracy

Ja, niżej podpisany:

imię (imiona) i nazwisko: **Bartosz Ziętek**

autor pracy dyplomowej pt. *„System do analizy sentymentu wiadomości finansowych w kontekście prognozowania ruchów giełdowych”*

Numer albumu: **350967**

Student Wydziału Nauk Ścisłych i Technicznych Uniwersytetu Śląskiego w Sosnowcu

kierunku studiów: Informatyka Inżynierska – studia niestacjonarne I stopnia.

Oświadczam, że w/w. praca dyplomowa:

- została przygotowana przeze mnie samodzielnie ¹,
- nie narusza praw autorskich oraz dóbr osobistych chronionych prawem cywilnym,
- nie zawiera danych i informacji, które uzyskałem w sposób niedozwolony,
- nie była podstawą nadania dyplomu uczelni wyższej lub tytułu zawodowego ani mnie, ani innej osobie.

Oświadczam również, że treść pracy dyplomowej zamieszczonej przeze mnie w Archiwum Prac Dyplomowych jest identyczna z treścią zawartą w wydrukowanej wersji pracy. Jestem świadomy odpowiedzialności karnej za złożenie fałszywego oświadczenia.

.....

Data

.....

Podpis autora pracy

¹. uwzględniając merytoryczny wkład promotora (w ramach prowadzonego seminarium dyplomowego)

Spis treści

1	Wstęp	1
1.1	Sens automatyzacji	2
1.2	Cel pracy	2
1.3	Ograniczenia projektu	3
2	Podstawy teoretyczne	4
2.1	Problem predykcji	4
2.1.1	Efektywność, a emocje	5
2.1.2	Wykorzystanie sztucznej inteligencji w finansach	5
2.2	Ewolucja analizy tekstu	6
2.2.1	Metoda słownikowa	6
2.2.2	Kontekst treści	6
2.3	Wykorzystanie uczenia maszynowego	7
2.4	Modele uczenia maszynowego w projekcie	8
2.4.1	Dlaczego XGBoost?	9
2.4.2	Podsumowanie działania	10
3	Projekt i implementacja systemu	11
3.1	Architektura systemu	11
3.2	Źródła danych	13
3.2.1	Dane giełdowe – Yahoo Finance	13
3.2.2	Dane tekstowe – Kaggle Financial News	13
3.3	Analiza sentymentu w systemie	13
3.4	Fuzja danych i logika łączenia danych	14
3.4.1	Problem wielu wiadomości	16
3.5	Klasyfikacja i model decyzyjny	17
3.6	Interfejs użytkownika	18

3.7	Wykorzystane technologie	18
3.7.1	Język programowania i środowisko	19
3.7.2	Pozyskiwanie i przetwarzanie danych	19
3.7.3	Sztuczna inteligencja i model predykcyjny	19
3.7.4	Warstwa prezentacyjna	20
4	Instrukcja obsługi aplikacji użytkownika	22
4.1	Tryby pracy aplikacji	23
4.2	Panel Inwestora	23
4.3	Symulacja historyczna	24
4.4	Dziennik decyzji	26
4.5	Panel Techniczny	27
5	Ewaluacja systemu i symulacja inwestycyjna	30
5.1	Metodyka testów	30
5.1.1	Podział danych	30
5.1.2	Kryteria oceny	31
5.1.3	Interpretacja wyników	31
5.2	Symulacja strategii inwestycyjnej	32
5.2.1	Scenariusze testowe	32
5.2.2	Wyniki symulacji	33
5.2.3	Analiza porównawcza	33
5.3	Wnioski końcowe z ewaluacji	34
5.3.1	Zalety rozwiązania	34
5.3.2	Ograniczenia badania	34
6	Podsumowanie i wnioski końcowe	36
6.1	Realizacja celów pracy	36
6.2	Wnioski i obserwacje	37
6.3	Potencjalny rozwój	37
6.4	Podsumowanie	38
	Bibliografia	40

Rozdział 1

Wstęp

Giełda to miejsce w którym w ustalonym czasie dochodzi do zakupu lub sprzedaży udziałów konkretnej spółki. Inwestor (czyli osoba grająca na giełdzie) może podejmować decyzję o zakupie lub sprzedaży w oparciu o tak zwaną **analizę fundamentalną**, badając jej zyski, straty, konkurencję na rynku i jej ogólną wartość. Próbuje on w ten sposób przewidzieć, czy wartość firmy wzrośnie, zmaleje, czy się nie zmieni. Innym sposobem pomagającym w podjęciu decyzji jest **analiza techniczna**, której głównym założeniem jest analiza historycznych zmian kursów, na której podstawie inwestor stara się przewidzieć przyszłość w myśl tego, że historia się powtarza.

Jest jeszcze jeden czynnik, który jest niezwykle istotny przy podejmowaniu decyzji o potencjalnych transakcjach na giełdzie - **emocje**. Człowiek nie jest maszyną i potencjalne straty lub zyski budzą w nas różne reakcje, od euforii po panikę. Przykładowo gdyby inwestor firmy Apple dowiedział się o tym, że najnowszy iPhone sprzedał się w rekordowo małej ilości przy jego premierze, prawdopodobnie w poczuciu niepokoju sprzedałby jej akcje spodziewając się spadku jej wartości. Ta praca inżynierska podejmuje próbę automatycznego badania wiadomości finansów i klasyfikowania ich jako pozytywnych, neutralnych lub negatywnych, co okazuje się przydatne w podejmowaniu decyzji o inwestowaniu.

1.1 Sens automatyzacji

Badania naukowe potwierdzają związek między nastrojami w mediach a zmianami cen akcji na giełdzie [13, 3]. Widać więc, że warto śledzić media grając na giełdzie. Natomiast można zadać sobie pytanie, po co właściwie nam system który się tym zajmuje, kiedy moglibyśmy zrobić to sami? Odpowiedzią na to pytanie jest skala. W dzisiejszych czasach, ilość nowych informacji, którymi codziennie jesteśmy zalewani jest nie- możliwa do przeanalizowania przez pojedynczego człowieka. Wraz z rozwojem sztucznej inteligencji, powstała możliwość oddelegowania jej tej pracy.

1.2 Cel pracy

Głównym założeniem było stworzenie inteligentnego asystenta, który byłby w stanie w czasie sekund przeanalizować setki artykułów i wy- ciągnąć na ich podstawie wnioski, czy cena danej akcji wzrośnie, czy spadnie.

W tym celu niezbędne było:

- **Zdobycie danych** - wykorzystano ceny wybranej akcji oraz nagłówki wiadomości z tego samego okresu.
- **Analiza sentymentu** - wykorzystanie modelu FinBERT, który potrafi zrozumieć kontekst oraz ocenić wydźwięk danego tekstu.
- **Obróbka i łączenie danych** - stworzenie głównego zbioru danych, porównując ceny akcji z nastrojami płynącymi z nowych wiadomości w celu znalezienia korelacji.
- **Trening modelu predykcyjnego** - trening algorytmu uczenia maszynowego (XGBoost), który na podstawie podanych informacji (w tym sentymentów) próbuje przewidzieć przyszłe ruchy cen akcji.

- **Stworzenie użytkowej aplikacji** - utworzenie interaktywnej strony internetowej na której użytkownik może zobaczyć analizę ceny wybranej akcji, zobaczyć na jakiej podstawie model tak myśli oraz dziennik poprzednich decyzji.

1.3 Ograniczenia projektu

W projekcie podjęto analizę na podstawie tylko jednej spółki - Apple. Została ona wybrana ze względu na jej popularność oraz dużą ilość generowanych wiadomości na jej temat.

Kolejnym ograniczeniem jest fakt, że system analizuje tylko nagłówki, a nie pełne treści nowych wiadomości. Jednak zaletą tego podejścia jest szybsze przetwarzanie.

System przewiduje zmianę ceny akcji jedynie na następny dzień.

Jednak architektura systemu jest uniwersalna - może w przyszłości być rozszerzona o inne źródła danych oraz potencjalny wybór innej spółki do analizy.

Rozdział 2

Podstawy teoretyczne

Przed budową systemu, musimy wyjaśnić sobie kilka fundamentalnych kwestii. Po pierwsze, w jaki sposób komputer jest w stanie “rozumieć” sentyment tekstu? Po drugie, czy giełdę da się przewidzieć? I finalnie, jak połączyć te wszystkie informacje w finalną predykcję?

W tym rozdziale zostały opisane ogólne obserwacje rynków finansowych, ewolucja metod analizy tekstu oraz wykorzystane narzędzia sztucznej inteligencji.

2.1 Problem predykcji

Zakładając hipotetyczny scenariusz, w którym inwestor ma dostęp do wszystkich możliwych informacji, takich jak bilans wszystkich spółek świata, historie każdej transakcji oraz analizy stworzone przez analityków, dalej nie jest w stanie mieć 100% pewności, czy cena danej akcji wzrośnie, czy spadnie.

Powodem tego braku pewności są emocje towarzyszące inwestorom. Pomimo dogłębnych analiz, bardzo łatwo o niepokój lub strach, kiedy na szali są prawdziwe pieniądze. Z tego względu, finalna cena akcji jest w pewien sposób uzależniona od ogólnego nastroju społeczeństwa.

2.1.1 Efektywność, a emocje

W świecie finansów od lat istnieje spór między podejściem Hipotezy Rynku Efektywnego, a podejściem behawioralnym

W podejściu Hipotezy Rynku Efektywnego Eugene’a Fama [6], sądzi się, że cena akcji jest odzwierciedleniem wszystkich dostępnych informacji na jej temat. Innymi słowy, jeżeli pojawi się dobra wiadomość o danej akcji, jej cena momentalnie wzrośnie i analogicznie, gdy pojawi się zła wiadomość - jej cena natychmiast spadnie.

W podejściu behawioralnym, Daniel Kahneman i Amos Tversky [7] udowodnili, że ludzie regularnie popełniają błędy w związku z oceną ryzyka. Natomiast Robert Shiller [11] udowodnił, że zmiany na giełdzie zachodzą szybciej i bardziej drastycznie, niż rzeczywiste zmiany w fundamentach spółek.

Prawda leży pośrodku - cena akcji jest uzależniona zarówno od suchych faktów, jak wolumen transakcji czy zmiana cen, natomiast inwestorzy dalej popełniają błędy. Sztuczna inteligencja jest w stanie pomóc w predykcji cen biorąc pod uwagę obydwa podejścia.

2.1.2 Wykorzystanie sztucznej inteligencji w finansach

Biorąc pod uwagę uwarunkowania statystyczne, możemy zaobserwować przykładowo **efektu momentum** - akcja, która przez jakiś czas rosła, ma tendencje do dalszego wzrostu. Jest to potencjalny czynnik, który może wychwycić sztuczna inteligencja i pomóc w poprawnej predykcji.

Z drugiej strony, można dostrzec opóźnioną reakcję cen akcji na wiadomości płynące ze świata. Aby cena w pełni zaadaptowała się do nowych wiadomości, często potrzebuje dni, a czasem nawet tygodni. Dodatkowo zdarza się, że inwestorzy za mocno reagują na dobre lub złe wiadomości - istnieją sytuacje, w których dobre wiadomości powodują zbyt duży wzrost, a złe za duży spadek. Dowodzi to, że jeżeli będziemy w

stanie lepiej i szybciej reagować na nowe informacje, to będziemy mogli potencjalnie zarobić.

Jeżeli tylko inwestor byłby w stanie lepiej i szybciej ocenić **nastrój rynku**, to prawdopodobnie mógłby podjąć lepszą decyzję. I to jest główny obiekt badań tej pracy - wykorzystanie narzędzi analizy tekstu przy pomocy sztucznej inteligencji. Możemy zadać sobie pytanie - jak komputer może “zrozumieć” nastrój płynący z tekstu, kiedy maszyna operuje tylko na liczbach?

2.2 Ewolucja analizy tekstu

2.2.1 Metoda słownikowa

Pierwszym podejściem zaproponowanym do rozwiązania tego problemu, była **metoda słownikowa** (ang. *lexicon-based*), która opierała się na idei stworzenia listy pozytywnych słów, takich jak wzrost, sukces, zysk oraz listy negatywnych słów, takich jak spadek, strata czy kryzys. Następnie w danym tekście zliczana była ilość wystąpień słowa negatywnych i pozytywnych, a następnie na podstawie tego, których słów było więcej, oceniano sentyment jako pozytywny lub negatywny.

Powstały wyspecjalizowane słowniki przeznaczone do finansów jak na przykład słownik Loughran-McDonald [8], w którym do każdego słowa jest przypisana jego emocjonalna wartość. Szybko jednak okazało się, że takie rozwiązanie ma pewne ograniczenia.

2.2.2 Kontekst treści

Język jest dużo bardziej skomplikowanym tworem, by dał się ocenić poprzez zliczanie słów. Problemem okazuje się kontekst. Słowa negatywne mogą występować w pozytywnych wiadomościach, jak i słowa pozytywne w negatywnych. Kilka przykładów:

1. **“Apple nie zanotował spadku sprzedaży”**

spadek = negatywne słowo, jednak wiadomość jako całość ma pozytywny wydźwięk

2. **“Analitycy spodziewali się lepszych wyników”**

lepszych = pozytywne słowo, natomiast z kontekstu można wnioskować, że jest to negatywna wiadomość

Widzimy tutaj, że pojedyncze słowo samo w sobie nie oddaje całej informacji jaka płynie ze zdania. Istotny jest kontekst w jakim dane słowo zostało użyte.

2.3 Wykorzystanie uczenia maszynowego

Rewolucją okazała się praca opublikowana w 2017 roku przez firmę Google pt. *“Attention Is All You Need”* [14], prezentując architekturę **Transformer**. Dwa lata później powstał model BERT [5], który zmienił podejście do przetwarzania języka naturalnego.

Model BERT został wytrenowany w sposób analogiczny do tego, jak dziecko uczy się języka - słyszy wielką ilość zdań w różnych kontekstach i na ich podstawie tworzy intuicje, co konkretne słowo znaczy, oraz w jakim kontekście się go używa. W bardzo podobny sposób został wytrenowany model BERT - uczył się na miliardach tekstów z internetu. Dodatkowo, zastosowano strategię, w której model musiał zgadywać losowo zakryte słowa.

Przykład:

“Apple ogłosił rekordowe wyniki [MASK] kwartalnym raporcie.”

Zadaniem modelu jest przewidzenie słowa w miejscu [MASK]. Aby to zrobić, model musi rozumieć **kontekst**.

BERT jest modelem z ogromną wiedzą ogólną, natomiast nie jest ona wyspecjalizowana. Z tego powodu powstał model **FinBERT** [1], który jest wyspecjalizowanym modelem BERT w dziedzinie rynków finansowych. Został dodatkowo wytrenowany na tekstach o tematyce rynkowych, co pozwala mu rozumieć żargon finansowy. W języku angielskim słowo "bearish" oznacza spekulacyjny, co nie musi oznaczać czegoś negatywnego, natomiast w kontekście giełdy, oznacza pesymizm.

W praktyce, model FinBERT czyta nagłówek oraz wystawia ocenę, co zilustrowano w Tabeli 2.1.

Tabela 2.1: Przykładowe wyniki oceny sentymentu przez model FinBERT

Nagłówek	Ocena	Pewność
“Apple przebija szacunki zysków”	Pozytywny	94%
“Sprzedaż iPhone’a rozczarowuje analityków”	Negatywny	87%
“Apple ogłasza nową linię produktów”	Neutralny	72%

Model dostarcza także informację, jak bardzo jest **pewny** swojej oceny. Treść wiadomości może być niejednoznaczna, przez co pewność spada.


2.4 Modele uczenia maszynowego w projekcie

Pomimo tego, że sentyment nowych informacji jest bardzo wartościowy, to niestety na tylko jego podstawie nie jesteśmy w stanie uzyskać wartościowych predykcji. Z tego powodu musimy również wziąć pod uwagę inne czynniki, takie jak trendy cenowe czy wolumen obrotu. Załóżmy, że otrzymujemy wiadomość “Apple ogłasza rekordowe zyski”, którego sentyment jest obiektywnie pozytywny, ale cena akcji jest poniżej swojej średniej ceny z ostatnich 50 dni oraz ilość transakcji jest niska. By pod-

jąc ostateczną decyzję inwestycyjną, należy wziąć pod uwagę wszystkie dostępne informacje.

Do tego zadania została wykorzystana biblioteka uczenia maszynowego XGBoost (eXtreme Gradient Boosting) [4], która pomogła w połączeniu tych informacji. Jest to algorytm bazujący na strukturze drzew decyzyjnych.

Uproszczony przykład pojedynczego drzewa decyzyjnego zaprezentowano na Rysunku 2.1.



Rysunek 2.1: Przykładowa struktura pojedynczego drzewa decyzyjnego

Mechanizm działania polega na iteracyjnej weryfikacji wartości cech wejściowych w kolejnych węzłach, co prowadzi do zwrócenia finalnej decyzji inwestycyjnej.

Wykorzystano tutaj technikę **boostingu** (wzmocnienia), która polega na stworzeniu wielu prostych drzew decyzyjnych i łączeniu ich w celu powstania jednego modelu predykcyjnego.

W praktyce, tworzone jest pierwsze drzewo, które popełnia błędy. Następnie tworzymy kolejne drzewo, które skupia się na błędach poprzedniego. Dalej powstaje kolejne drzewo, które skupia się na błędach dwóch poprzednich. Po iteracji przez około 150 takich drzew, algorytm podejmuje decyzję.

2.4.1 Dlaczego XGBoost?

XGBoost wyróżnia się odpornością na szum - ma on wbudowane mechanizmy, które chronią model przed zjawiskiem **przetrenowania**, czyli

zbyt mocnym dopasowaniu się do podanego zbioru danych. Gdy model jest przetrenowany, traci zdolność do generalizacji.

Ma również wbudowane narzędzia pozwalające sprawdzić, na co model zwraca największą uwagę przy podejmowaniu decyzji.

Dodatkowo, jest szybki, pozwala na skalowalność oraz umożliwia operację na różnych typach danych.

2.4.2 Podsumowanie działania

Schemat przepływu i przetwarzania danych w systemie:

1. **Wiadomość** (np. “Apple przebija kwartalne oczekiwania”) trafia do modelu **FinBERT**.
2. Model FinBERT ocenia sentyment wiadomości **np. pozytywny, 89% pewności**.
3. Ta ocena, wraz z danymi rynkowymi (cena, wolumen, trend), trafia do **XGBoosta**.
4. XGBoost “pyta swój komitet”: Czy przy takim sentymencie, takiej cenie i takim wolumenie cena jutro wzrośnie?
5. Komitet głosuje i wydaje werdykt: **Prognoza: WZROST, prawdopodobieństwo: 67%**.


Rozdział 3

Projekt i implementacja systemu

Niniejszy rozdział przedstawia opis projektowania utworzonego oprogramowania oraz wykorzystaną architekturę. Szczególną uwagę poświęcono wyzwaniom inżynierskim, takim jak przetwarzanie danych, synchronizacja czasu z wiadomościami oraz optymalizacja uczenia modelu.

3.1 Architektura systemu

Ogólny schemat przepływu danych i architekturę zrealizowanego systemu przedstawiono na Rysunku 3.1.



Rysunek 3.1: Architektura systemu – przepływ danych od surowych informacji do decyzji inwestycyjnej

3.2 Źródła danych

3.2.1 Dane giełdowe – Yahoo Finance

Historyczne notowania akcji Apple (ticker: AAPL) zostały pobrane z serwisu Yahoo Finance za pomocą biblioteki `yfinance`.

Zakres danych: 1 stycznia 2020 – 1 stycznia 2021 (254 dni sesyjne)

Ten okres został wybrany ze względu na początek pandemii COVID-19, który charakteryzował się ekstremalną zmiennością na giełdzie. W tym czasie media generowały bardzo dużo wiadomości, co powodowało różnorodność nastrojów – od paniki do euforii.

Pobierane kolumny to: cena otwarcia, cena maksymalna, cena minimalna, cena zamknięcia oraz wolumen obrotu.

3.2.2 Dane tekstowe – Kaggle Financial News

Wiadomości finansowe pochodzą ze zbioru “**Analyst Ratings Processed**”¹ z platformy Kaggle, zawierającego ponad milion artykułów z portali finansowych i rekomendacji analityków.

Po przefiltrowaniu dla spółki Apple w roku 2020 uzyskano **471 nagłówków wiadomości**. Przykładowe rekordy z tego zbioru przedstawiono w Tabeli 3.1.

3.3 Analiza sentymentu w systemie

Przefiltrowane nagłówki ze zbioru Kaggle poddawane są analizie sentymentu przy pomocy modelu FinBERT, korzystając z biblioteki **transformers**. W praktyce, proces ten polega na utworzeniu instancji klasyfikatora, do którego iteracyjnie przekazywane są kolejne wiadomości.

¹Zbiór danych dostępny w serwisie Kaggle pod adresem: <https://www.kaggle.com/datasets/miguelaenlle/massive-stock-news-analysis-db-for-nlpbacktests>

Tabela 3.1: Przykładowe wiadomości ze zbioru danych Kaggle

Nagłówek	Data	Sentyment
“UBS utrzymuje rekomendację do kupna dla Apple...”	2020-03-10	neutral
“Apple zamyka wszystkie sklepy poza Chinami...”	2020-03-14	negative
“Apple ogłasza rekordowe przychody za kwartał...”	2020-07-30	positive

Biblioteka **transformers** pozwala na tokenizację tekstu oraz wyciąganie z niego wniosków bez wcześniejszej budowy własnej sieci neuronowej.

Model FinBERT dla każdego nagłówka zwraca etykietę: **positive** (pozytywny), **negative** (negatywny) lub **neutral** (neutralny).

Dodatkowo, zwraca również pewność predykcji (score), który jest wyrażany jako wartość zmiennoprzecinkowa z przedziału (0, 1].

Te wyniki są łączone z główną ramką danych biblioteki **Pandas**, tworząc nowe kolumny z wartościami dla konkretnego dnia.

3.4 Fuzja danych i logika łączenia danych


Największym problemem w trakcie tworzenia projektu okazał się problem związany z weekendami. Giełda nowojorska (NYSE) prowadzi sesje inwestycyjne w dni robocze. Jednak wiadomości na temat spółek pojawiają się codziennie, również w te dni, kiedy nie odbywają się sesje inwestycyjne. Tworzy to problem w integracji nowych informacji z konkretnymi datami. Rozważmy przykład z marca 2020 roku, zobrazowany w Tabeli 3.2:

Tabela 3.2: Problem asynchroniczności danych – weekend marcowy 2020

Data	Dzień	Wydarzenie
13 marca 2020	Piątek	Ostatnia sesja giełdowa
14 marca 2020	Sobota	News: “Apple zamyka sklepy poza Chinami”
15 marca 2020	Niedziela	News: “Fed tnie stopy procentowe do zera”
16 marca 2020	Poniedziałek	Pierwsza sesja – historyczny krach (-12%)

Gdyby pominąć wiadomości z soboty oraz niedzieli, utracone zostałyby bardzo istotne informacje.

Rozwiązaniem okazał się algorytm `merge_asof`, który pozwala na “przyciągnięcie” wiadomości do najbliższej sesji giełdowej. Wizualizację działania tego mechanizmu przedstawiono na Rysunku 3.2.



Rysunek 3.2: Wizualizacja działania algorytmu `merge_asof` – weekendowe wiadomości są “przyciągane” do poniedziałkowej sesji

Implementacja tego mechanizmu w języku Python została zaprezentowana na Listingu 3.1.

Listing 3.1: Fuzja temporalna z algorytmem merge_asof

```

1 # Sortowanie jest wymagane przez merge_asof
2 df_prices = df_prices.sort_values('Date')
3 daily_sentiment = daily_sentiment.sort_values('Date')
4
5 # Łaczenie danych ("przyciąganie" do tyłu)
6 df_final = pd.merge_asof(
7     df_prices,                # Tabela lewa (giełda)
8     daily_sentiment,          # Tabela prawa (newsy)
9     on='Date',                # Klucz łączenia
10    direction='backward',     # Szukaj w przeszłości
11    tolerance=pd.Timedelta('3_days') # Maks. 3 dni wstecz
12 )

```

Warto zwrócić uwagę na **tolerance='3 days'**. Wartość 3 dni oznacza, że brane są pod uwagę wiadomości z maksymalnie 3 dni wstecz.

3.4.1 Problem wielu wiadomości

Kolejnym problemem przy integracji danych okazał się fakt, że danego dnia może pojawić się więcej niż jedna wiadomość, która mogłaby wpłynąć na cenę akcji. Aby rozwiązać ten problem, zastosowano sposób uśredniania sentymentu. Gdy danego dnia pojawia się na przykład 5 różnych wiadomości, system oblicza **średni ważony sentyment dnia**:

$$\text{Sentyment_dnia} = \frac{1}{N} \sum_{i=1}^N \text{score}_i \times \text{znak}(\text{etykieta}_i) \quad (3.1)$$

gdzie:

- score_i – pewność modelu (np. 0.87 oznacza 87% pewności),
- $\text{znak}(\text{etykieta}_i) = +1$ dla positive, -1 dla negative, 0 dla neutral.

Praktyczny przykład takiego uśredniania sentymentu ukazuje Tabela 3.3. Logikę uśredniania w języku Python przedstawiono na Listingu 3.2.

Tabela 3.3: Agregacja sentymentu dla przykładowego dnia

Nagłówek	Etykieta	Score	Wynik
„Apple ogłasza rekordowe przychody”	positive	0.92	+0.92
„Problemy z łańcuchem dostaw uderzają w iPhone’a”	negative	0.78	−0.78
„Tim Cook zabierze głos podczas konferencji”	neutral	0.65	0.00
Średni sentyment dnia:			+0.047

Wynik +0.047 oznacza **lekko pozytywny** nastrój – pozytywna wiadomość o rekordach była silniejsza niż negatywna o problemach z dostawami.

Listing 3.2: Obliczanie dziennego sentymentu

```

1 def apply_sign(row):
2     if row['sentiment_label'] == 'positive':
3         return row['sentiment_score']
4     elif row['sentiment_label'] == 'negative':
5         return -row['sentiment_score']
6     return 0.0
7
8 news_df['signed_score'] = news_df.apply(apply_sign, axis=1)
9 daily_sentiment = news_df.groupby('Date')['signed_score'].mean()

```

3.5 Klasyfikacja i model decyzyjny

Gdy dane są już ze sobą zintegrowane, są przekazywane do modelu predykcyjnego opartego na algorytmie **XGBoost**. Algorytm ten przyjmuje na wejściu trójwymiarowy wektor cech, składający się z danych rynkowych oraz analizy sentymentu. Zdefiniowany wektor cech opisano szczegółowo w Tabeli 3.4.

Proces wnioskowania polega na jednoczesnej analizie tych trzech wymiarów. Wynikiem działania jest binarna predykcja: 1 (wzrost) lub 0 (spadek). Ta predykcja kończy fazę analityczną całego systemu i jest

Tabela 3.4: Wektor cech wykorzystywany przez model decyzyjny

Nr	Cecha	Interpretacja
1	Avg_Sentiment	Wskaźnik sentymentu dziennego. Numeryczna reprezentacja nastrojów medialnych
2	Volume	Dzienny wolumen obrotu, wskazujący na intensywność handlu oraz siłę danego trendu
3	Close	Cena akcji przy zamknięciu poprzedniej sesji. Informuje o aktualnej wycenie akcji

przekazywana do interfejsu użytkownika.

3.6 Interfejs użytkownika

Ostatnim elementem jest interfejs użytkownika – zdecydowano się na stworzenie interaktywnej aplikacji internetowej, która na bieżąco prezentuje wyniki działania modelu. Do tego zadania wykorzystano bibliotekę **Streamlit**, która pozwala na bezpośrednie renderowanie komponentów webowych z poziomu języka Python, bez użycia standardowych narzędzi do tworzenia systemów internetowych, takich jak HTML/CSS/JavaScript.

3.7 Wykorzystane technologie

System został stworzony w oparciu o nowoczesne technologie używane w komercyjnych produktach. Podstawą implementacji był język Python, wokół którego zbudowano architekturę przy użyciu wielu bibliotek programistycznych. Poniżej przedstawiono listę wszystkich wykorzystanych narzędzi wraz z uzasadnieniem ich wyboru.

3.7.1 Język programowania i środowisko

Językiem wykorzystanym do stworzenia całego potoku przetwarzania danych (pipeline) oraz warstwy serwerowej był Python (wersja 3.x). Wybór ten był oczywisty ze względu na dominującą pozycję tego języka w branży sztucznej inteligencji i Data Science. Python oferuje szereg dojrzałych bibliotek, które pozwalają na szybką integrację różnych komponentów systemu, od pobierania danych sieciowych, przez skomplikowane obliczenia, aż po implementację interfejsu graficznego.

3.7.2 Pozyskiwanie i przetwarzanie danych

Do pobrania danych oraz ich przetworzenia zostały wykorzystane dwie biblioteki:

- **Pandas** [9]: Biblioteka, na której oparta jest cała część analityczna projektu. Została wykorzystana do przechowywania, czyszczenia oraz transformacji zbiorów danych do struktury **DataFrame**. Była kluczowa w kontekście wykonywania obliczeń oraz obsługi szeregów czasowych. Problem asynchroniczności danych z poszczególnymi dniami został rozwiązany przy użyciu algorytmu `merge_asof` z tej biblioteki.
- **yfinance** [2]: Otwartoźródłowy moduł, który pozwala na komunikację z publicznym interfejsem programowania aplikacji (API - Application Programming Interface) serwisu Yahoo Finance. Został wykorzystany do zautomatyzowanego pobierania historycznych notowań spółki Apple. Zapewnił dostęp do danych rynkowych, takich jak cena akcji przy zamknięciu sesji czy wolumen.

3.7.3 Sztuczna inteligencja i model predykcyjny

Do analizy sentymentu wiadomości finansowych oraz implementacji modelu predykcyjnego zostały wykorzystane takie biblioteki jak:

- **Transformers (Hugging Face)** [15]: Jest to zaawansowana biblioteka dostarczająca narzędzia programistyczne do pracy z nowoczesnymi modelami opartymi na architekturze Transformer. W tym projekcie posłużyła do pobrania i uruchomienia pretrenowanego modelu FinBERT. Pozwoliła ona na pominięcie ręcznej implementacji mechanizmów uwagi.
- **XGBoost** [4]: Biblioteka, która implementuje algorytm eXtreme Gradient Boosting. Była podstawą w budowie modelu decyzyjnego. Wybór ten był podyktowany wysoką skutecznością na tabelarycznych zbiorach danych oraz wbudowanymi mechanizmami regularyzacji, które chronią model przed zjawiskiem przetrenowania.

3.7.4 Warstwa prezentacyjna

Wszechstronność języka Python pozwala na tworzenie w pełni funkcjonalnych aplikacji internetowych w obrębie tylko tego języka. Do tego zadania wykorzystane zostały takie biblioteki jak:

- **Streamlit** [12]: Nowoczesny framework przeznaczony do budowy interaktywnych aplikacji internetowych bezpośrednio z poziomu języka Python. Wykorzystanie tego narzędzia wyeliminowało konieczność używania takich technologii jak HTML, CSS czy JavaScript. Umożliwił on także stworzenie responsywnego interfejsu użytkownika.
- **Plotly** [10]: Biblioteka pozwalająca na tworzenie interaktywnych wizualizacji danych, renderowanych w przeglądarce. W tym projekcie zastąpiła ona często wykorzystywaną, standardową bibliotekę, jaką jest Matplotlib. Przy jej użyciu zaimplementowano wszystkie wykresy. Dodatkowo daje ona możliwość przybliżania osi czasu oraz włączania lub wyłączania poszczególnych zmiennych. Pozwala

także na odczytywanie dokładnych wartości analitycznych po najechaniu na wykres kursorem.


Rozdział 4

Instrukcja obsługi aplikacji użytkownika

W tym rozdziale przedstawiona została dokumentacja aplikacji użytkownika. Dashboard Inwestora to narzędzie, które pozwala na interakcję z wytrenowanym modelem przez użytkownika, bez konieczności znajomości pojęć technicznych związanych ze sztuczną inteligencją.

4.1 Tryby pracy aplikacji

Aplikacja została zaprojektowana w sposób modułowy. Każdy moduł stanowi oddzielny widok. Strukturę nawigacji wraz z poszczególnymi powiązaniem zaprezentowano na Rysunku 4.1.



Rysunek 4.1: Struktura nawigacji aplikacji – cztery główne tryby pracy


4.2 Panel Inwestora

Panel Inwestora to domyślny ekran aplikacji. Jak pokazano na Rysunku 4.2, wyświetlana jest tu bieżąca cena akcji z procentową stopą zwrotu, zysk zakładający poszczególne strategie inwestycyjne oraz dotychczasową trafność prognoz.

Pod wykresem znajduje się sekcja “Prognoza na Następną Sesję”. Znajduje się tu rekomendacja modelu co do dalszych działań inwestycyjnych. Obok znajdują się dane wejściowe modelu, na których podstawie model podjął taką decyzję. Ten element systemu możemy zobaczyć na Rysunku 4.3.




Rysunek 4.2: Panel Inwestora – główny widok aplikacji z interaktywnym wykresem porównującym strategie inwestycyjne




Rysunek 4.3: Panel Inwestora – prognoza na następną sesję z rekomendacją i szczegółami analizy

4.3 Symulacja historyczna

Aplikacja zawiera również możliwość wyboru dowolnej daty z przeszłości w celu sprawdzenia, jak wówczas zachował się model. Zgodnie z interfejsem zaprezentowanym na Rysunku 4.4, użytkownik ma do dyspozycji interaktywny kalendarz. Pod historycznym wykresem, są również wyświetlone wiadomości z konkretnego dnia, którymi kierował się model przy podejmowaniu decyzji. Ta sekcja została zaprezentowana na Rysunku 4.5.



Rysunek 4.4: Suwak pozwala wybrać dowolną datę z przeszłości i zobaczyć decyzję systemu wraz z oceną jej trafności



Rysunek 4.5: Wykres z przeszłości wraz z wiadomościami na których podstawie model podjął wówczas decyzje

4.4 Dziennik decyzji

Moduł Dziennik Decyzji przedstawiony na Rysunku 4.6 zawiera tabelaryczne zestawienie decyzji z wybranego okresu z prognozą modelu. Decyzja modelu jest porównana z odzwierciedleniem w rzeczywistości, dając możliwość weryfikacji skuteczności modelu. Pod tabelą znajdują się przycisk “Pobierz jako CSV” dający możliwość eksportu danych do pliku CSV.

Nad tabelą ze szczegółowymi informacjami znajduje się liczba decyzji, ilość trafionych decyzji oraz procent skuteczności predykcji modelu. Jest tu również sekcja “Jak system podejmuje decyzje?“, która zawiera krótki opis dla użytkownika, by mógł lepiej zrozumieć działanie systemu. Ta sekcja jest przedstawiona na Rysunku 4.7.

Filtruj: ☒ Wszystkie ☐ Tylko trafione ☒ Tylko błędne

	Data	Cena	Sentyment	Prognoza	Rzeczywistość	Trafione?
78	2020-04-24	\$68.44	0.0000	Wzrost	Spadek	✗
77	2020-04-23	\$66.52	-0.9620	Wzrost	Wzrost	✓
76	2020-04-22	\$66.78	0.0000	Spadek	Spadek	✓
75	2020-04-21	\$64.91	0.0000	Wzrost	Wzrost	✓
74	2020-04-20	\$66.98	0.0000	Wzrost	Spadek	✗
73	2020-04-17	\$68.40	0.0000	Spadek	Spadek	✓
72	2020-04-16	\$69.34	0.0000	Spadek	Spadek	✓
71	2020-04-15	\$68.79	0.8210	Wzrost	Wzrost	✓
70	2020-04-14	\$69.42	-0.8770	Spadek	Spadek	✓
69	2020-04-13	\$66.09	0.0000	Wzrost	Wzrost	✓

Pobierz jako CSV

Rysunek 4.6: Dziennik Decyzji – tabela z pełną historią predykcji systemu wraz z oznaczeniem trafień oraz pudeł

Dziennik Decyzji Systemu Deploy

Historia wszystkich decyzji z oceną trafności

▼ Jak system podejmuje decyzje?

Jak interpretować decyzje systemu?

System działa w trzech krokach:

- Zbieranie wiadomości** – dla każdego dnia zbierane są wszystkie nagłówki artykułów o Apple.
- Analiza sentymentu** – model FinBERT ocenia każdy nagłówek osobno, przypisując mu wartość:
 - Pozytywny (+0.5 do +1.0) np. "Apple notuje rekordowe zyski"
 - Negatywny (-0.5 do -1.0) np. "Problemy z dostawami iPhone'a"
 - Neutralny (około 0) np. "Apple ogłasza datę konferencji"
- Agregacja** – jeśli danego dnia było np. 3 artykuły (+0.8, -0.3, +0.5), system oblicza średnią: $\text{Średni sentyment} = (+0.8 - 0.3 + 0.5) / 3 = +0.33$ (umiarkowanie pozytywny)
- Decyzja** – model XGBoost analizuje średni sentyment, cenę i wolumen, a następnie przewiduje kierunek zmiany ceny na następny dzień.

Uwaga: Jeden bardzo negatywny artykuł może "przebić" kilka umiarkowanie pozytywnych – tak jak w prawdziwym życiu, złe wiadomości często mają większy wpływ na rynki.

Liczba decyzji: 9 Trafione: 8 Skuteczność: 88.9%

Rysunek 4.7: Dziennik Decyzji – tabela z pełną historią predykcji systemu wraz z oznaczeniem trafień i pudeł

4.5 Panel Techniczny

Moduł Panel Techniczny jest przeznaczony dla zaawansowanych użytkowników. Na Rysunku 4.8 można zaobserwować wykres liniowy zmiany akcji wraz ze wskaźnikiem sentymentu.


Moduł ten posiada również zakładkę "Statystyki" w której znajduje się tablica ze statystykami opisowymi takimi jak średnia czy odchylenie standardowe (Rysunek 4.9) oraz macierz korelacji, ułatwiająca badanie zależności między zmiennymi (Rysunek 4.10).

Ostatnią zakładką tego modułu jest zakładka “Surowe Dane”, w której istnieje możliwość obserwacji tabeli z surowymi danymi (Rysunek 4.11).

Panel Techniczny

Szczegółowe dane i analiza dla zaawansowanych użytkowników

Wykres Cen i Sentymentu Statystyki Surowe Dane




Rysunek 4.8: Panel Techniczny – interaktywny wykres ceny akcji i sentymentu na dwóch osiach Y

Statystyki opisowe

	Cena	Wolumen	Sentiment
count	12.00	12.00	12.00
mean	67.07	153260166.67	-0.01
std	1.80	31735090.22	0.54
min	64.35	116862400.00	-0.96
25%	65.79	129051700.00	0.00
50%	66.88	144139800.00	0.00
75%	68.53	171919300.00	0.00
max	69.42	215250000.00	0.94

Rysunek 4.9: Panel Techniczny – statystyki opisowe danych (średnia, odchylenie standardowe, kwartyle)

Korelacje



Rysunek 4.10: Panel Techniczny – macierz korelacji między zmiennymi (sentyment, cena, wolumen)

Panel Techniczny

Szczegółowe dane i analiza dla zaawansowanych użytkowników

☒ Wykres Cen i Sentymentu
 ☒ Statystyki
 ☒ Surowe Dane

	Date	Close	Volume	Avg_Sentiment	Target
78	2020-04-24 00:00:00+00:00	68.4369	126161200	0	1
77	2020-04-23 00:00:00+00:00	66.5166	124814400	-0.962	1
76	2020-04-22 00:00:00+00:00	66.7753	116862400	0	0
75	2020-04-21 00:00:00+00:00	64.9058	180991600	0	1
74	2020-04-20 00:00:00+00:00	66.9761	130015200	0	0
73	2020-04-17 00:00:00+00:00	68.3958	215250000	0	0
72	2020-04-16 00:00:00+00:00	69.3366	157125200	0	0
71	2020-04-15 00:00:00+00:00	68.7899	131154400	0.821	1
70	2020-04-14 00:00:00+00:00	69.4236	194994800	-0.877	0
69	2020-04-13 00:00:00+00:00	66.0861	131022800	0	1

Rysunek 4.11: Panel Techniczny – podgląd surowych danych

Rozdział 5

Ewaluacja systemu i symulacja inwestycyjna

W tym rozdziale przedstawiono wyniki testów systemu, skupiających się na weryfikacji rzeczywistej wartości biznesowej. Przeprowadzono symulację działania systemu na danych historycznych. Pozwoliło to na ocenę realnej skuteczności podejmowanych decyzji, oraz czy korzystanie z systemu pozwala na osiągnięcie przewagi na rynku finansowym.

5.1 Metodyka testów

5.1.1 Podział danych

Walidacja modelu została przeprowadzona na danych, których algorytm nie widział w trakcie procesu uczenia. W ten sposób uniknięto zjawiska wycieku danych (data leakage), który charakteryzuje się zafałszowaniem wyników - model mógłby pamiętać wyniki zamiast je przewidywać.

Zastosowano podział chronologiczny:

- **Zbiór treningowy (80%):** dane od 1 stycznia do 30 września 2020 (203 dni sesyjne) – na tym okresie model uczył się zależności

między sentymentem a ceną.

- **Zbiór testowy (20%):** dane od 1 października do 31 grudnia 2020 (51 dni sesyjnych) – ten okres został użyty do finalnej weryfikacji skuteczności modelu.

Wybrany okres testowy (IV kwartał 2020) charakteryzował się silnym trendem wzrostowym, co stworzyło trudne środowisko do analizy strategii opartych na wykrywaniu ryzyka, ponieważ każda decyzja o sprzedaży akcji wiąże się z ryzykiem utraty potencjalnych zysków.

5.1.2 Kryteria oceny

W tradycyjnym uczeniu maszynowym podstawową metryką jest trafność (Accuracy). Jednak w systemach finansowych sama trafność może się okazać myląca, ponieważ model może mieć trafność 90% na dniach o małej zmienności, ale gdy pomyli się w jednym, znaczącym dniu w którym cena spadła o na przykład 30%, może doprowadzić to do większych strat.

Z tego powodu skuteczność modelu była oceniana na podstawie trafności oraz stopy zwrotu z inwestycji (ROI) oraz Maksymalnego Obsunięcia Kapitału (Max Drawdown), czyli miary ryzyka.

5.1.3 Interpretacja wyników

Model na zbiorze testowym osiągnął trafność (Accuracy) na poziomie 62.75%. Oznacza to, że model poprawnie przewidział kierunek zmiany ceny akcji w około 63% przypadków. Można interpretować ten wynik jako satysfakcjonujący, biorąc pod uwagę losowy charakter rynków finansowych, w których wynik powyżej 55% uznaje się za sukces.

Szczegółowa analiza metryk (Tabela 5.1) wskazuje na istotną charakterystykę modelu:

Model charakteryzuje się **wysoką precyzją dla wzrostów (71%)**. Gdy system zwraca sygnał "KUP", prawdopodobieństwo wzrostu wyniosło ponad 70%. Z drugiej strony, można zwrócić uwagę na konserwatyzm modelu - osiągnął on niski wskaźnik **czułości (Recall)**, co oznacza że woli on pominąć momenty niepewności, które mogłyby być ryzykowne.

Tabela 5.1: Kluczowe metryki modelu klasyfikacyjnego (Zbiór testowy)

Metryka	Wartość	Interpretacja biznesowa
Trafność (Accuracy)	62.75%	Ogólna skuteczność systemu
Precyzja (Precision)	71.00%	Wiarygodność sygnałów kupna
Czułość (Recall)	46.00%	Zdolność do wykrywania wszystkich okazji

5.2 Symulacja strategii inwestycyjnej

Weryfikacja finansowa polegała na symulacji portfela inwestycyjnego w okresie testowym (X-XII 2020).

5.2.1 Scenariusze testowe


Porównano dwie strategię:

1. **Strategia pasywna („Kup i Trzymaj”)**: Zakłada ona zakup akcji Apple w pierwszym dniu testu i sprzedanie ich ostatniego dnia testu, ignorując sygnały rynkowe.
2. **Strategia aktywna (Stworzony system sztucznej inteligencji)**: Zakłada dynamiczną alokację kapitału:
 - Sygnał **WZROST** → Utrzymuj/Kup akcje (100% kapitału w akcjach).
 - Sygnał **SPADEK** → Sprzedaj akcje (100% kapitału w gotówce).

Symulację przeprowadzono z kapitałem początkowym **10 000 USD**.

5.2.2 Wyniki symulacji

Na Rysunku 5.1 przedstawiono krzywą narastania kapitału dla obu porównywanych strategii na przestrzeni badanego kwartału.



Rysunek 5.1: Krzywa kapitału: Strategia AI (niebieska) vs Strategia Pasywna (czarna). Płaskie odcinki niebieskiej linii oznaczają wyjście do gotówki.

5.2.3 Analiza porównawcza

Wyniki finansowe symulacji przedstawiono w Tabeli 5.2.

Tabela 5.2: Wyniki finansowe strategii (Okres: IV kwartał 2020)

Wskaźnik	Kup i Trzymaj	Strategia AI	Różnica
Kapitał końcowy	\$11 549	\$11 489	−\$60
Stopa zwrotu (ROI)	+15.49%	+14.89%	−0.6 p.p.
Max Drawdown	−7.44%	−5.68%	+1.76 p.p.

Analiza wykresu i tabeli prowadzi do następujących wniosków:

1. W badanym okresie, akcje Apple zyskały na wartości ponad 15%. Strategia AI, pomimo okresowego wychodzenia z rynku, osiągnęła wynik gorszy o tylko 0.6 punktu procentowego. Oznacza to, że system nie generował wielu fałszywych sygnałów sprzedaży.
2. Najważniejszym osiągnięciem systemu jest zmniejszenie maksymalnego obsunięcia kapitału (Max Drawdown) z 7.44% do 5.68%. Oznacza to redukcję ryzyka o blisko 24%. System poprawnie identyfikował zagrożenie, przechodząc w stan gotówki.

5.3 Wnioski końcowe z ewaluacji

Przeprowadzone testy potwierdziły, że system oparty na fuzji sentymentu (FinBERT) i danych rynkowych (XGBoost) jest w stanie przynieść rzeczywistą wartość w podejmowaniu decyzji o inwestycjach na giełdzie.

5.3.1 Zalety rozwiązania

- **Stabilność:** System oferuje małe zmiany cen, unikając ryzyka.
- **Automatyzacja:** System eliminuje czynnik emocjonalny w trakcie podejmowania decyzji inwestycyjnej.
- **Skuteczność predykcji:** Trafność na poziomie 63% jest wysokim wynikiem, który należy uznać za potencjalnie wartościowy.

5.3.2 Ograniczenia badania

Należy wziąć pod uwagę pewne ograniczenia przyjętej metodyki testowej:

- **Krótki okres testu:** Z uwagi na konieczność zachowania separacji danych treningowych od testowych, symulacja skupiła się na

tylko jednym kwartale.

- **Specyfika okresu:** IV kwartał 2020 był okresem wzrostowym. Pełna ocena systemu wymagałaby przetestowania go w warunkach długotrwałych spadków.
- **Koszty transakcyjne:** W symulacji pominięto prowizje maklerskie, które w rzeczywistości mogłyby wpłynąć negatywnie na wynik strategii aktywnej.

Rozdział 6

Podsumowanie i wnioski końcowe

Celem tej pracy inżynierskiej było zaprojektowanie i implementacja systemu informatycznego, który korzysta z narzędzi analizy tekstu (NLP) do osiągnięcia przewagi na rynku inwestycyjnym. Główna teza pracy zakładała, że emocje płynące z wiadomości finansowych można użyć do podjęcia decyzji inwestycyjnych.

Zrealizowany projekt udowodnił, że wykorzystanie nowoczesnych modeli językowych (FinBERT) w połączeniu z danymi rynkowymi pozwala na stworzenie narzędzia, które przewiduje kierunek zmian cen z skutecznością wyższą od rzutu monetą (63%), oraz zarządza ryzykiem inwestycyjnym.

6.1 Realizacja celów pracy

Wszystkie postawione cele zostały zrealizowane:

1. **Agregacja danych:** Stworzono potok (*pipeline*) przetwarzania danych, który łączy asynchroniczne strumienie informacji, przez notowania giełdowe, po wiadomości prasowe.

2. **Analiza sentymentu:** Wykorzystano model FinBert, który poprawnie klasyfikuje wiadomości finansowe, pomimo specjalistycznego języka finansowego.
3. **Model predykcyjny:** Wytrenowano model XGBoost, który na podstawie sentymentu, wolumenu oraz ceny generuje decyzje inwestycyjne.
4. **Aplikacja użytkownika:** Wyniki modelu zostały udostępnione w postaci aplikacji webowej, wyposażonej w możliwość analizy symulacji historycznej oraz sprawdzenia poprawnych decyzji modelu.

6.2 Wnioski i obserwacje

Podczas realizacji projektu, wyciągnięto kilka kluczowych wniosków. Po pierwsze sentyment to nie wszystko. Pierwsze testy wykazały, że sam sentyment nie daje satysfakcjonujących efektów. Należało połączyć sentyment z danymi rynkowymi, by osiągnąć satysfakcjonujące wyniki. Po drugie, zaobserwowano podejście defensywne sztucznej inteligencji. Okazało się, że największą wartością jej dodania nie jest maksymalizacja zysków, a minimalizacja strat.

6.3 Potencjalny rozwój

Zaprojektowany system ma charakter modułowy, co pozwala na jego potencjalną rozbudowę. Potencjalnym kierunkiem rozwoju mogłaby być **Analiza czasu rzeczywistego**, czyli podpięcie systemu pod dynamiczny potok danych, w celu analizy wiadomości w czasie rzeczywistym. Inną potencjalną drogą rozwoju mogłaby być adaptacja modelu do rynku kryptowalut. Jest on znany z jeszcze większego wpływu mediów społecznościowych na zmiany cen, co mogłoby potencjalnie zwiększyć skuteczność systemu. Finalnie, istnieje możliwość wykorzystania modeli

które potrafiłyby nie tylko oceniać sentyment, ale dodatkowo streszczać pełne teksty artykułów.

6.4 Podsumowanie

Niniejsza praca inżynierska pokazała, że bariera wejścia do zaawansowanej analityki finansowej jest znacząco niższa, dzięki ogólnodostępnym bibliotekom oraz pretrenowanym modelom językowym. Nietrudno jest stworzyć narzędzie, które jeszcze dekadę temu było zarezerwowane dla specjalistów w dziedzinie inwestycji. Stworzona aplikacja nie może zastąpić doświadczonego inwestora, jednak stanowi narzędzie wspomagające, które jest w stanie przeczytać tysiące nagłówków w ułamku sekundy.

Bibliografia

- [1] Dogu Araci. FinBERT: Financial sentiment analysis with pre-trained language models. *arXiv preprint arXiv:1908.10063*, 2019.
- [2] Ran Aroussi. yfinance: Yahoo! finance market data downloader. <https://github.com/ranaroussi/yfinance>, 2020.
- [3] Johan Bollen, Huina Mao, Xiaojun Zeng. Twitter mood predicts the stock market. *Journal of Computational Science*, 2(1):1–8, 2011.
- [4] Tianqi Chen, Carlos Guestrin. XGBoost: A scalable tree boosting system. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, strongy 785–794. ACM, 2016.
- [5] Jacob Devlin, Ming-Wei Chang, Kenton Lee, Kristina Toutanova. BERT: Pre-training of deep bidirectional transformers for language understanding. *arXiv preprint arXiv:1810.04805*, 2019. Proceedings of NAACL-HLT 2019.
- [6] Eugene F. Fama. Efficient capital markets: A review of theory and empirical work. *The Journal of Finance*, 25(2):383–417, 1970.
- [7] Daniel Kahneman, Amos Tversky. Prospect theory: An analysis of decision under risk. *Econometrica*, 47(2):263–291, 1979.
- [8] Tim Loughran, Bill McDonald. When is a liability not a liability? textual analysis, dictionaries, and 10-ks. *The Journal of Finance*, 66(1):35–65, 2011.

- [9] Wes McKinney. Data structures for statistical computing in python. *Proceedings of the 9th Python in Science Conference*, strony 56–61, 2010.
- [10] Plotly Technologies Inc. Collaborative data science. <https://plot.ly>, 2015.
- [11] Robert J. Shiller. From efficient markets theory to behavioral finance. *Journal of Economic Perspectives*, 17(1):83–104, 2003.
- [12] Streamlit Inc. Streamlit: The fastest way to build and share data apps. <https://streamlit.io/>, 2023.
- [13] Paul C. Tetlock. Giving content to investor sentiment: The role of media in the stock market. *The Journal of Finance*, 62(3):1139–1168, 2007.
- [14] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Łukasz Kaiser, Illia Polosukhin. Attention is all you need. *Advances in Neural Information Processing Systems*, wolumen 30, strony 5998–6008. Curran Associates, Inc., 2017.
- [15] Thomas Wolf, Lysandre Debut, Victor Sanh, Julien Chaumond, Clement Delangue, Anthony Moi, Pierric Cistac, Tim Rault, Remi Louf, Morgan Funtowicz, i in. Transformers: State-of-the-art natural language processing. *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing: System Demonstrations*, strony 38–45. Association for Computational Linguistics, 2020.